

Lokales KI-Aufnahmestudio für animierte YouTube-Videos

Eine verständliche Anleitung für Schülerinnen und Schüler

Vom einzelnen Prompt zum fertigen Video – ohne Cloud-API

Manus AI · 16. September 2026

Inhalt

1 Die wichtigste Idee	1
2 Was bedeutet „Anlernen“ und „Trainieren“?	1
3 Zielbild: eine lokale Video-Pipeline	1
4 Hardware und lokale Grenzen	2
5 Die Bausteine des Studios	3
5.1 1. Lokales Sprachmodell für Planung und Text	3
5.2 2. Figurenkonsistenz statt Zufallsbilder	3
5.3 3. Animation in kurzen Clips	3
5.4 4. Sprache und Voice Cloning	4
5.5 5. Untertitel und Schnitt	4
6 Vom Prompt zum ersten Testvideo	4
7 So wird aus mehreren Programmen ein „Ein-Prompt-Studio“	5
8 Wann lohnt sich Feintuning?	6
9 Rechte, Sicherheit und Verantwortung	6
10 Lernplan für vier Wochen	6
11 Checkliste für die erste fertige Fassung	7
12 Kurzfazit	7
13 Quellen	7

1 Die wichtigste Idee

Du musst eine KI nicht zuerst komplett neu trainieren, damit sie ein animiertes YouTube-Video erstellen kann. Für ein lokales Studio ist meistens eine **Pipeline** besser: Mehrere spezialisierte Programme arbeiten nacheinander zusammen. Ein lokales Sprachmodell schreibt das Drehbuch. Ein Bild- oder Videomodell erzeugt Szenen. Ein Sprachmodell spricht den Text. Ein Schnittprogramm setzt Bild, Sprache, Musik und Untertitel zu einer Videodatei zusammen.

Merksatz: Ein Prompt ist der Auftrag. Ein Workflow ist die Produktionsstraße. Ein Training verändert ein Modell dauerhaft. Für den Anfang brauchst du vor allem einen guten Workflow.

Das Studio kann vollständig auf dem eigenen Rechner laufen. Dafür werden Modelle und Programme einmal heruntergeladen. Danach können Drehbücher, Audios und Videos ohne Übertragung an eine Cloud erzeugt werden. ComfyUI ist beispielsweise eine lokale, modulare Oberfläche, die Bild-, Video-, Audio- und Text-Workflows als wiederverwendbare Knotenpläne organisiert und auch offline laufen kann. [1]

2 Was bedeutet „Anlernen“ und „Trainieren“?

In Gesprächen werden drei verschiedene Dinge oft verwechselt.

Begriff	Was passiert?	Wann ist es sinnvoll?
Prompting	Du gibst einem vorhandenen Modell einen klaren Auftrag.	Immer. Das ist der erste Schritt.
Workflow	Du verbindest mehrere Modelle und Programme zu einer festen Produktionsfolge.	Für wiederholbare Videos mit gleichbleibendem Ablauf.
RAG / Wissensbasis	Das Modell liest lokale Dateien, zum Beispiel Figurenbeschreibungen oder Fakten.	Wenn eine Serie eigene Regeln, Namen und Hintergrundwissen hat.
LoRA / Feintuning	Du passt ein Modell mit kleinen Zusatzgewichten an einen Stil oder eine Figur an.	Wenn dieselbe Figur oder derselbe Zeichenstil sehr stabil bleiben soll.
Vollständiges Training	Ein großes Modell wird mit sehr vielen Beispielen neu trainiert.	Für ein Schul- oder kleines Studio-Projekt normalerweise nicht nötig.

Wichtig: Beim Training werden nicht einfach „Wünsche“ in die KI hineingeschrieben. Man braucht Daten, eine klare Lizenz, Rechenzeit, Speicherplatz und eine Messung, ob das Ergebnis besser geworden ist. Für ein einzelnes YouTube-Video lohnt sich vollständiges Training fast nie.

3 Zielbild: eine lokale Video-Pipeline

Die Pipeline wird am besten in kleine, kontrollierbare Schritte geteilt:

1. **Idee:** Thema, Zielgruppe, Länge und Stil festlegen.
2. **Drehbuch:** Ein lokales Sprachmodell schreibt Szenen, Dialog und Sprecheranweisungen.
3. **Szenenplan:** Das Drehbuch wird in kurze Shots zerlegt. Jeder Shot erhält ein Bildziel und eine Bewegungsbeschreibung.
4. **Figuren und Bilder:** Referenzbilder, Hintergründe und Requisiten lokal erzeugen oder selbst zeichnen.
5. **Animation:** Aus Bildern oder Text entstehen kurze Videoclips. Wan2.1 unterstützt unter anderem Text-zu-Video, Bild-zu-Video und Videobearbeitung; das Projekt ist in ComfyUI integriert. [2]
6. **Sprache:** Ein lokales Text-to-Speech-System spricht die Dialoge. Piper ist ein schnelles lokales TTS-System; die aktive Entwicklung liegt inzwischen beim Projekt piper1-gpl. [3] Für Voice Cloning kann XTTS-v2 mit einem kurzen Referenz-Audio arbeiten, unterstützt Deutsch und weist ausdrücklich auf seine eigene Modelllizenz hin. [4]
7. **Untertitel und Schnitt:** Whisper kann Sprache lokal transkribieren. FFmpeg verbindet Video-, Audio- und Untertitelströme. [5] [6]
8. **Kontrolle:** Das fertige Video wird angesehen, angehört und auf Fehler geprüft.

Ein einzelner Prompt kann diese Schritte später auslösen. Am Anfang sollte man sie jedoch getrennt testen. So erkennt man, ob ein Fehler aus dem Drehbuch, dem Bildmodell, dem Sprachmodell oder dem Schnitt kommt.

4 Hardware und lokale Grenzen

Lokale KI bedeutet nicht, dass der Rechner unbegrenzt schnell ist. Besonders Videoerzeugung benötigt viel Grafikspeicher. Als grobe Lernregel gilt: Eine moderne NVIDIA-Grafikkarte mit 12 bis 24 GB VRAM ist für viele lokale Bild- und kleinere Videoworkflows deutlich angenehmer als eine reine CPU-Nutzung. Weniger VRAM kann mit Quantisierung, Modell-Offloading und kleineren Auflösungen funktionieren, dauert aber länger.

Wan2.1 nennt für das kleinere T2V-1.3B-Modell etwa 8,19 GB VRAM und beschreibt eine 5-Sekunden-480p-Erzeugung auf einer RTX 4090 in ungefähr vier Minuten ohne Optimierungen. Das ist ein Richtwert, keine Garantie für jeden Rechner. [2] Das größere 14B-Modell ist deutlich anspruchsvoller.

Bereich	Empfehlung für den Einstieg	Warum?
GPU	NVIDIA mit 12–24 GB VRAM	Viele Modelle und Tools sind dafür gut dokumentiert.
Arbeitsspeicher	32 GB RAM oder mehr	Modelle, Videoframes und Schnittprogramm teilen sich den Speicher.
Speicherplatz	Mindestens 200 GB frei, besser mehr	Modelle können mehrere Gigabyte groß sein; Videos benötigen zusätzlich Platz.
Betriebssystem	Windows oder Linux	Beide Systeme haben lokale Tools. Linux ist bei manchen Entwickler-Workflows einfacher.

Internet	Nur für Download und Updates	Die eigentliche Produktion kann danach lokal erfolgen.
----------	------------------------------	--

5 Die Bausteine des Studios

5.1 1. Lokales Sprachmodell für Planung und Text

Ollama ist eine einfache Möglichkeit, lokale Sprachmodelle zu starten und über eine lokale REST-API anzusprechen. Ein Aufruf an localhost bleibt auf dem eigenen Rechner. [7] Für den Anfang genügt ein Modell, das gut Deutsch schreibt und strukturierte Antworten liefern kann.

Ein gutes Drehbuch-Prompt enthält mindestens:

1. Zielgruppe und Alter
2. Thema und Lernziel oder Unterhaltungsidee
3. Videolänge und Anzahl der Szenen
4. Stil der Figuren und der Sprache
5. Regeln für Dialoge, Erzählstimme und Bildbeschreibungen
6. Ein festes Ausgabeformat, zum Beispiel JSON oder eine Tabelle

Beispiel-Prompt für das Drehbuch

„Du bist Drehbuchautor für eine freundliche Animationsserie für 10- bis 13-Jährige. Schreibe eine Geschichte über 90 Sekunden in sechs Szenen. Jede Szene enthält: Dauer, Bildbeschreibung, Kamerabewegung, Sprechertext, Geräusch und Übergang. Nutze einfache deutsche Sätze. Die Figur Lumo ist ein neugieriger Roboter mit gelbem Rucksack. Halte Aussehen und Persönlichkeit in jeder Szene gleich. Gib ausschließlich JSON aus.“

5.2 2. Figurenkonsistenz statt Zufallsbilder

Bildmodelle können schöne Einzelbilder erzeugen, aber sie verändern bei jeder neuen Generierung leicht Gesicht, Kleidung oder Farben. Deshalb werden zuerst Referenzbilder erstellt. Eine Figurenkarte sollte Name, Alter, Form, Farben, Kleidung, typische Haltung und verbotene Abweichungen beschreiben. Danach wird pro Szene eine Referenz oder ein Startbild verwendet.

ComfyUI ist dafür geeignet, weil Workflows als JSON gespeichert und wiederverwendet werden können. Die gleiche Ausgangsdatei, der gleiche Seed und dieselben Einstellungen machen Ergebnisse besser vergleichbar. [1]

5.3 3. Animation in kurzen Clips

Für stabile Ergebnisse werden keine zehn Minuten am Stück erzeugt. Besser sind kurze Clips von ungefähr drei bis sechs Sekunden. Diese Clips werden später zusammengeschnitten. Das reduziert Fehler und macht es möglich, nur eine misslungene Szene neu zu erzeugen.

Ein Bewegungs-Prompt sollte nicht nur das Motiv wiederholen. Er beschreibt, was sich bewegt und was ruhig bleibt:

„Lumo steht im selben gelben Rucksack vor der Werkbank. Die Kamera fährt langsam von links nach rechts. Lumo hebt die linke Hand und zeigt auf eine leuchtende Schraube. Ruhige, freundliche 2D-Animation. Hintergrund und Gesicht bleiben stabil. Keine zusätzlichen Figuren, kein Text im Bild.“

5.4 4. Sprache und Voice Cloning

Für normale Sprecherstimmen ist eine lokale Piper-Stimme oft der einfachste Start. Wenn eine eigene Stimme oder eine ausdrücklich erlaubte Sprecherstimme verwendet werden soll, kann XTTS-v2 eine Alternative sein. Ein Referenz-Audio darf nur verwendet werden, wenn die betroffene Person eindeutig zugestimmt hat. Die Zustimmung sollte schriftlich vorliegen und die Nutzung, Veröffentlichungsorte und Dauer nennen.

Voice Cloning ist nicht dasselbe wie eine Synchronsprecherin zu imitieren. Eine Stimme ist ein personenbezogenes Merkmal. Ohne Einwilligung darf man sie nicht klonen oder als echt ausgeben. Bei einer synthetischen Stimme ist außerdem zu prüfen, ob die Modell- und Stimmenlizenz die Veröffentlichung auf YouTube erlaubt.

5.5 5. Untertitel und Schnitt

Whisper kann eine Audiodatei lokal in Text umwandeln und eignet sich dadurch für Untertitel. Das Modell unterstützt mehrere Sprachen. Die offizielle Dokumentation nennt verschiedene Modellgrößen mit unterschiedlichen Speicher- und Geschwindigkeitsanforderungen. [5]

FFmpeg kann Bildsequenzen, Videoclips, Sprache und Untertitel zusammenführen. Bei einer Folge aus vielen Bildern ist ein typischer Baustein:

```
ffmpeg -f image2 -framerate 12 -i shot-%03d.jpeg -s 1280x720 clip.mp4
```

Für ein finales Video sollte der Export ein verbreitetes Format verwenden, zum Beispiel MP4 mit H.264-Video und AAC-Audio. Ein Schnittprogramm wie Kdenlive oder DaVinci Resolve kann zusätzlich für Musik, Lautstärke, Titel und manuelle Korrekturen verwendet werden. Die KI nimmt dir die Kontrolle nicht ab: Ein Mensch prüft die letzte Fassung.

6 Vom Prompt zum ersten Testvideo

Arbeite nicht sofort an einem kompletten zehnminütigen Film. Erstelle zuerst einen 20- bis 30-sekündigen Test mit drei Szenen.

1. Lege einen Projektordner an: 01_drehbuch, 02_referenzen, 03_bilder, 04_clips, 05_audio, 06_untertitel, 07_export.
2. Schreibe das Drehbuch mit sechs kurzen Szenen.
3. Erzeuge eine Figurenkarte und zwei Referenzbilder.
4. Erzeuge pro Szene zunächst ein Standbild. Prüfe die Figur, bevor du animierst.
5. Erzeuge aus den besten Bildern kurze Bewegungsclips.
6. Erzeuge die Sprecherdateien. Benenne sie nach Szene und Sprecher, zum Beispiel s01_lumo.wav.
7. Transkribiere die fertige Sprache und korrigiere die Untertitel von Hand.
8. Setze alles im Schnittprogramm zusammen und exportiere eine Testfassung.

Qualitätskontrolle nach jedem Schritt: Ist die Handlung verständlich? Bleibt die Figur erkennbar? Passt die Sprache zur Szene? Gibt es falsche Hände, zusätzliche Gegenstände, unverständliche Wörter oder Lizenzprobleme? Je früher du prüfst, desto weniger musst du später neu machen.

7 So wird aus mehreren Programmen ein „Ein-Prompt-Studio“

Wenn der manuelle Test funktioniert, wird der Ablauf automatisiert. Das bedeutet nicht, dass man eine riesige neue KI trainiert. Man baut eine kleine Anwendung, die einen Auftrag entgegennimmt und anschließend lokale Programme aufruft.

Der Auftrag kann intern in diese Daten aufgeteilt werden:

```
{
  "titel": "Lumo und die verlorene Schraube",
  "zielgruppe": "10-13 Jahre",
  "dauer_sekunden": 90,
  "stil": "freundliche 2D-Animation",
  "sprache": "de",
  "sprecher": ["Lumo", "Erzähler"],
  "format": "youtube-16-9"
}
```

Danach erstellt der Orchestrator zunächst das Drehbuch. Er prüft, ob alle Szenen vorhanden sind. Anschließend startet er für jede Szene das Bild- oder Videomodell. Nach der Spracherzeugung werden Audios und Bilder im Schnittschritt zusammengefügt. Am Ende schreibt das Programm ein Protokoll mit Modellnamen, Versionen, Seeds, Dateinamen und Fehlern.

Ein späterer Ablauf könnte so aussehen:

Prompt

```
-> lokales Sprachmodell
-> scenes.json
-> Figuren- und Bildworkflow
-> kurze Videoclips
-> lokale Sprachsynthese
-> Whisper-Untertitel
-> FFmpeg oder Schnittprogramm
-> review.mp4
```

Für jeden Schritt sollte es einen Neustartpunkt geben. Wenn nur Szene 4 schlecht ist, wird nur Szene 4 neu gerendert. Das spart Zeit und verhindert, dass eine kleine Korrektur alles verändert.

8 Wann lohnt sich Feintuning?

Ein Feintuning mit LoRA kann sinnvoll sein, wenn eine Serie sehr oft dieselbe Figur, denselben Zeichenstil oder bestimmte Produkte zeigen soll. Für ein sauberes Ergebnis braucht man viele rechtmäßig nutzbare Beispiele, möglichst mit unterschiedlichen Posen, Blickrichtungen und Situationen. Die Bilder müssen beschriftet und stilistisch konsistent sein.

Ein sinnvolles Lernexperiment ist eine kleine LoRA für eine selbst erfundene Figur. Dabei werden nur eigene Zeichnungen oder eindeutig lizenzierte Bilder verwendet. Verglichen werden drei Versionen: das Basismodell, das Basismodell mit Referenzbild und das Basismodell mit LoRA. Bewertet werden Figuren-ähnlichkeit, Bildqualität, Vielfalt und Rechenzeit.

Nicht trainieren sollte man vorschnell:

1. wenn nur ein einzelnes Video entstehen soll
2. wenn die Trainingsbilder aus dem Internet stammen und die Rechte unklar sind
3. wenn das Problem eigentlich ein zu ungenauer Prompt oder ein fehlendes Referenzbild ist
4. wenn der Rechner die Trainings- und Testläufe nicht zuverlässig schafft

9 Rechte, Sicherheit und Verantwortung

Lokale Verarbeitung schützt Daten vor einer Cloud-Übertragung, ersetzt aber nicht die Prüfung von Rechten. Vor der Veröffentlichung sollten fünf Fragen beantwortet sein:

1. Sind die Figuren, Bilder, Musik und Geräusche selbst erstellt oder rechtmäßig lizenziert?
2. Liegt eine Einwilligung für jede geklonte Stimme vor?
3. Erlauben Modell, Checkpoint, LoRA und Stimme die geplante Veröffentlichung?
4. Wird das Video so gestaltet, dass Zuschauerinnen und Zuschauer nicht über eine echte Person oder ein echtes Ereignis getäuscht werden?
5. Sind Quellen, Versionen und verwendete Assets im Projektprotokoll dokumentiert?

Auch ein lokales Modell kann falsche Aussagen erzeugen. Fakten, Namen und Zitate werden deshalb von einer Person geprüft. Bei Unterrichtsprojekten gehört diese Prüfung zum Lernziel: KI erzeugt Vorschläge, aber Verantwortung und Veröffentlichung bleiben beim Menschen.

10 Lernplan für vier Wochen

Woche	Ziel	Ergebnis
1	Lokal starten und Prompts verstehen	Ein lokales Sprachmodell schreibt ein Drehbuch mit Szenenstruktur.
2	Figuren und Bilder stabilisieren	Eine Figurenkarte und drei passende Referenzbilder.
3	Sprache, Animation und Untertitel	Ein 20- bis 30-sekündiger Clip mit Sprache und Untertiteln.
4	Workflow und Rechte prüfen	Eine dokumentierte Testfassung mit Quellen- und Lizenzliste.

11 Checkliste für die erste fertige Fassung

1. Der Prompt nennt Thema, Zielgruppe, Stil, Länge und Ausgabeformat.
2. Das Drehbuch ist in einzelne Shots zerlegt.
3. Die Figurenkarte liegt im Projektordner.
4. Jeder Shot besitzt einen nachvollziehbaren Prompt, Seed und Dateinamen.
5. Die Stimme wurde mit Erlaubnis verwendet und klingt verständlich.
6. Untertitel wurden nicht blind übernommen, sondern gelesen und korrigiert.
7. Musik und Bilder haben eine geklärte Lizenz.
8. Das Video wurde vollständig angesehen und angehört.
9. Alle Modellversionen und Einstellungen sind dokumentiert.

12 Kurzfazit

Ein lokales KI-Aufnahmestudio entsteht nicht durch einen magischen Super-Prompt. Es entsteht durch eine gut geplante Kette aus spezialisierten, lokal laufenden Werkzeugen. Der beste Start ist ein kleines Testvideo. Erst wenn Drehbuch, Figuren, Sprache, Animation und Schnitt einzeln funktionieren, wird daraus ein automatisierter Ein-Prompt-Workflow.

Die sinnvollste Reihenfolge lautet: **erst verstehen, dann testen, danach automatisieren und erst ganz zum Schluss gezielt feintunen.**

13 Quellen

- [1] [ComfyUI – offizielle Projektseite und Dokumentation.](#)
- [2] [Wan2.1 – offizielle Projektseite, Modelle und lokale Inferenzhinweise.](#)
- [3] [Piper – aktuelles offizielles Repository der lokalen TTS-Engine.](#)
- [4] [Coqui XTTS-v2 – Modellkarte, Sprachen, Voice Cloning und Lizenz.](#)
- [5] [OpenAI Whisper – offizielle Projektseite, Modelle und lokale Transkription.](#)
- [6] [FFmpeg – offizielle Dokumentation zu Streams, Sequenzen und Export.](#)
- [7] [Ollama – offizielles Repository und lokale REST-API.](#)

Hinweis: Software, Modelle, Lizenzen und Hardwareempfehlungen ändern sich. Vor einer Veröffentlichung müssen die aktuellen Lizenzbedingungen der konkret verwendeten Version geprüft werden.